

Comparação de Filtros de Pré-Processamento para Identificação de Esferas com Hough Circles na OBR

Gustavo Chagas Andrade¹

¹Programa de Pós-Graduação em Ciência da Computação (PPG-CC)
Universidade Federal de São Paulo (UNIFESP)
São José dos Campos – SP – Brasil

1. Introdução

A detecção de objetos circulares em imagens, como esferas, depende de haver um pré-processamento para otimizar os resultados. Este estudo investiga o uso do algoritmo Hough Circles em conjunto com diferentes técnicas para identificar as esferas. Esta pesquisa é especialmente motivada pelo contexto das competições da Olimpíada Brasileira de Robótica (OBR).

A OBR é uma competição científica que envolve desafios práticos e teóricos de robótica. Na modalidade prática, os robôs autônomos enfrentam cenários simulados, como a sala de resgate, onde devem localizar e resgatar esferas que representam vítimas.

Este estudo busca resolver esse problema ao comparar a eficiência de diversos filtros de pré-processamento de imagem, como: Sobel, dilatação, Canny (edges) e blur, na melhoria da precisão e confiabilidade da detecção de esferas pelo algoritmo Hough Circles. A análise comparativa visa determinar o melhor filtro ou combinação de filtros para maximizar a taxa de sucesso na detecção das esferas.

2. Problema a ser resolvido

A detecção precisa das esferas é desafiadora devido a diversos fatores, como variações na iluminação, presença de ruído, sobreposições e deformações das esferas, além de diferenças nas condições de captura das imagens. As esferas podem ser pretas ou revestidas por papel alumínio, o que acrescenta complexidade ao processo de identificação. Na Olimpíada Brasileira de Robótica (OBR), especificamente na modalidade prática, a tarefa dos robôs é identificar e manipular esferas de isopor que representam vítimas em ambientes simulados, como a sala de resgate. A precisão na identificação dessas esferas é crucial para o sucesso das missões dos robôs.

A técnica de Hough Circles é amplamente utilizada para detectar formas circulares em imagens, mas sua eficácia pode ser significativamente afetada pelas condições mencionadas acima. Portanto, o desafio reside em identificar quais técnicas de pré-processamento de imagem são mais eficazes para melhorar a performance do algoritmo Hough Circles na detecção de esferas em diferentes cenários.

3. Pré-processamento

O objetivo principal do pré-processamento é melhorar a qualidade da imagem de forma a aumentar as chances para o sucesso dos processos seguintes.

As imagens originais são coloridas e convertidas em escala de cinza, além de possuírem dimensões de 4640x3488 pixels, para tornar o processamento mais rápido

optou-se por aplicar um `resize` na imagem, a transformando em 1160x872 pixels (4x menos). Após aplicar o redimensionamento na imagem, é realizado um corte em 35% na altura da imagem, ou seja de 872 pixels passa a ser 567 pixels, a região onde ocorre o corte não existe nenhuma esfera, assim obtemos uma região de interesse, diminuindo a quantidade de cálculos necessários nas próximas etapas.

Os quatro filtros adotados nesse trabalho, Sobel, dilatação, Canny (edges) e blur, são descritos abaixo:

3.1. Blur

Projetada para suavizar imagens, esse filtro desempenha um papel fundamental na redução de ruídos e imperfeições enquanto preserva detalhes importantes, como bordas e características distintivas da imagem, o `medianBlur` adotado utiliza uma abordagem que substitui cada pixel pela mediana dos valores dos pixels em uma janela especificada, geralmente de tamanho ímpar e positivo [Eisenkraemer 2016], em nossa aplicação foi adotado o kernel = (7,7), chegou-se nesse valor após testes es amostra de imagens.

3.2. Canny

O detector de bordas de Canny é uma técnica eficaz para identificar bordas em uma imagem. O processo começa com o desfoque da imagem em tons de cinza usando um filtro gaussiano, o qual suaviza as transições de intensidade entre pixels. Em seguida, é calculada a magnitude e direção do gradiente utilizando o operador Sobel, destacando variações abruptas de intensidade [Eisenkraemer 2016]. Este cálculo é essencial para a detecção precisa de bordas circulares, importante na transformada de Hough. A supressão de não-máximos é então aplicada para afinar as bordas, preservando apenas os gradientes mais intensos e descartando os demais. Aqui, a magnitude do gradiente no pixel atual é comparada com a dos seus vizinhos na direção do gradiente, que é quantizada em ângulos discretos (0°, 45°, 90°, 135°).

Após a supressão de não-máximos, a função `cv2.Canny()` do OpenCV é utilizada para aplicar o limiar duplo. Nesta etapa, os pixels são classificados em três categorias com base em dois parâmetros ajustáveis empiricamente: os limiares inferior (`threshold1`) e superior (`threshold2`), que os adotados nesse trabalho são 35 e 100 respectivamente. Pixels com magnitude abaixo do limiar inferior são descartados como sem borda, enquanto os pixels com magnitude acima do limiar superior são considerados bordas fortes. Pixels com magnitude entre esses dois limiares são classificados como bordas fracas.

Finalmente, o rastreamento de bordas por histerese decide quais bordas fracas devem ser mantidas. Uma borda fraca é mantida se estiver conectada a uma borda forte, caso contrário, é descartada como ruído. Este processo assegura que apenas bordas significantes e robustas contra o ruído sejam incluídas na imagem final de bordas detectadas pelo algoritmo de Canny, proporcionando uma detecção precisa e eficaz das bordas na imagem.

3.3. Dilate

A função de dilatação em processamento de imagens é uma operação morfológica que visa expandir regiões de pixels de alta intensidade em uma imagem, como os pertencentes a objetos, em relação aos pixels de fundo. Esse processo preenche os espaços, unir

partes separadas de objetos e realçar características específicas de uma imagem digital. Utilizando um kernel retangular, que define a vizinhança ao redor de cada pixel, a função `cv2.dilate()` do OpenCV substitui o valor de cada pixel pelo valor máximo encontrado dentro da área coberta pelo kernel. Isso resulta na expansão das áreas de objetos conforme a aplicação repetida da operação, aumentando progressivamente o tamanho dessas regiões na imagem processada [Eisenkraemer 2016].

3.4. Sobel

O operador Sobel é uma técnica que estima a magnitude e a direção do gradiente em cada pixel de uma imagem em tons de cinza, destacando áreas de alta variação de intensidade que indicam bordas.

Sobel é obtido pela convolução das derivadas parciais x e y da imagem com filtros Sobel- x e Sobel- y , respectivamente. Esses filtros são essencialmente máscaras ponderadas que calculam a magnitude do gradiente em direções horizontal e vertical. O filtro Gaussiano é aplicado antes dessa operação para reduzir o ruído na imagem, melhorando a precisão da detecção de bordas.

Esse algoritmo pode ser resumido em quatro etapas principais: primeiro, a conversão da imagem para tons de cinza para simplificar o processamento; em seguida, a aplicação do filtro Sobel- x para calcular as variações de intensidade na direção horizontal; depois, o filtro Sobel- y é aplicado para calcular as variações verticais; por fim, a magnitude e a direção do gradiente são calculadas a partir das derivadas parciais, fornecendo informações detalhadas sobre as bordas presentes na imagem [Rizal et al. 2020].

3.5. Hough Circles

A transformada de Hough é um método eficaz para identificar formas geométricas como linhas, círculos e elipses em imagens digitais. Sua principal vantagem reside na capacidade de reconhecer essas formas mesmo quando suas bordas não estão completamente definidas, sendo robusta a imperfeições no formato dos objetos.

Inicialmente desenvolvida para detectar linhas, a transformada de Hough foi expandida para incluir também a identificação de elipses e círculos. Em muitos casos, especialmente ao identificar círculos ou elipses, é comum aplicar filtros de detecção de borda como etapa de pré-processamento. No entanto, devido a imperfeições na imagem original ou no próprio algoritmo de detecção de bordas, podem ocorrer lacunas nas bordas ou contornos dos objetos, dificultando a identificação precisa.

Para superar esses desafios, a transformada de Hough agrupa as bordas detectadas em possíveis objetos candidatos por meio de um processo de votação. Este método permite que apenas os objetos que mais se assemelham à forma desejada sejam selecionados como resultados da técnica, melhorando significativamente a precisão e a robustez da detecção de formas geométricas complexas em imagens digitais.

A detecção de circunferências com raio fixo envolve identificar quais pontos de uma imagem pertencem a uma circunferência de raio r . Para isso, utiliza-se a transformada de Hough, onde cada ponto (x, y) na imagem contribui para uma matriz, conhecida como espaço de Hough, onde as colunas e linhas representam os possíveis centros (xc, yc) das circunferências. Inicialmente, todas as células dessa matriz têm valor zero. Para cada

ponto (x, y) da imagem, incrementa-se as células no espaço de Hough correspondentes aos centros das circunferências de raio r que passam por (x, y) . As células com valores mais altos indicam os centros mais prováveis das circunferências.

A equação paramétrica tradicional $r^2 = (x - xc)^2 + (y - yc)^2$ não é a mais eficiente para calcular todos os valores de (xc, yc) para um ponto específico (x, y) . Em vez disso, utiliza-se uma representação em coordenadas polares, onde:

$$xc = x - r \cdot \cos(\theta)$$

$$yc = y - r \cdot \sin(\theta)$$

Essas equações simplificam a busca pelos centros das circunferências no espaço de Hough, usando conceitos básicos de trigonometria.

O algoritmo para criação do espaço de Hough a partir de uma imagem envolve marcar os pixels da borda com um valor alto (por exemplo, 255) e os demais pixels com um valor baixo (por exemplo, 0). Após a criação do espaço, a detecção de circunferências resume-se a encontrar os picos no espaço de Hough. É fundamental destacar que a transformada de Hough é aplicável apenas quando é possível distinguir na imagem original os pontos que pertencem ao contorno ou borda dos objetos [Aggarwal 2012].

4. Metodologia

Para o desenvolvimento do trabalho proposto, foram obtidas 219 imagens de esferas de isopor utilizadas em cenários simulados, elas tem 5 cm de diâmetro e estão revestidas com papel alumínio ou tingida de preta, representando as condições encontradas na modalidade de resgate da Olimpíada Brasileira de Robótica (OBR).

Cada imagem foi rotulada utilizando a plataforma online CVAT (Computer Vision Annotation Tool). Esse processo envolveu a marcação das esferas presentes nas imagens, construindo uma base de dados para a avaliação dos algoritmos de detecção. As anotações foram realizadas traçando caixas delimitadoras sobre cada esfera, seguindo critérios específicos. As esferas bem visíveis foram rotuladas com o label "esferas", enquanto as esferas parcialmente ocultas, sobrepostas ou parcialmente fora do campo de visão da imagem foram rotuladas com o label "esferas-ocultas". Este critério de rotulação permite a distinção entre esferas de fácil e difícil detecção, proporcionando assim uma avaliação dos filtros de pré-processamento e dos parâmetros do algoritmo Hough Circles em condições variadas.

Após a rotulação, foram desenvolvidos códigos em Python para aplicar os filtros e executar o HoughCircles, além de outro código para geração dos gráficos para as etapas 1, 2 e 3. Os gráficos foram obtidos através do uso de planilhas eletrônicas. Os testes foram divididos em três etapas, variando os valores dos parâmetros do HoughCircles como consta na tabela 1:

O script principal desenvolvido onde atua o HoughCircles, segue o seguinte fluxo de execução, como ilustrado na figura 1. Para cada imagem do diretório o pré-processamento é realizado, em seguida a imagem passa pelos filtros Blur, Sobel, Dilate e Canny, possuindo assim 4 instancias de imagens filtradas, após isso o HoughCircles é aplicado individualmente. As circunferência identificadas são comparadas aos círculos

Parâmetro de HC	Etapa 1	Etapa 2	Etapa 3
dp	1.04, 1.05, 1.06	1.04, 1.05	1.05
minDist	40, 80, 120	20, 40, 120	20
param1	85, 100, 115	75, 85, 115	75
param2	10, 15, 20	10, 15, 20	15
minRadius	10, 15, 20	15, 20	15
maxRadius	145, 165, 185	145, 165	165

Tabela 1. Parâmetros utilizados em cada etapa do estudo.

anotados (rotulados), calculando a distância entre seus centros. Para cada círculo anotado, a função busca o círculo detectado mais próximo que esteja dentro de um limite aceitável (menor ou igual a 20). Se encontrar um círculo detectado mais próximo que os anteriores, ela atualiza o círculo mais próximo e a menor distância.

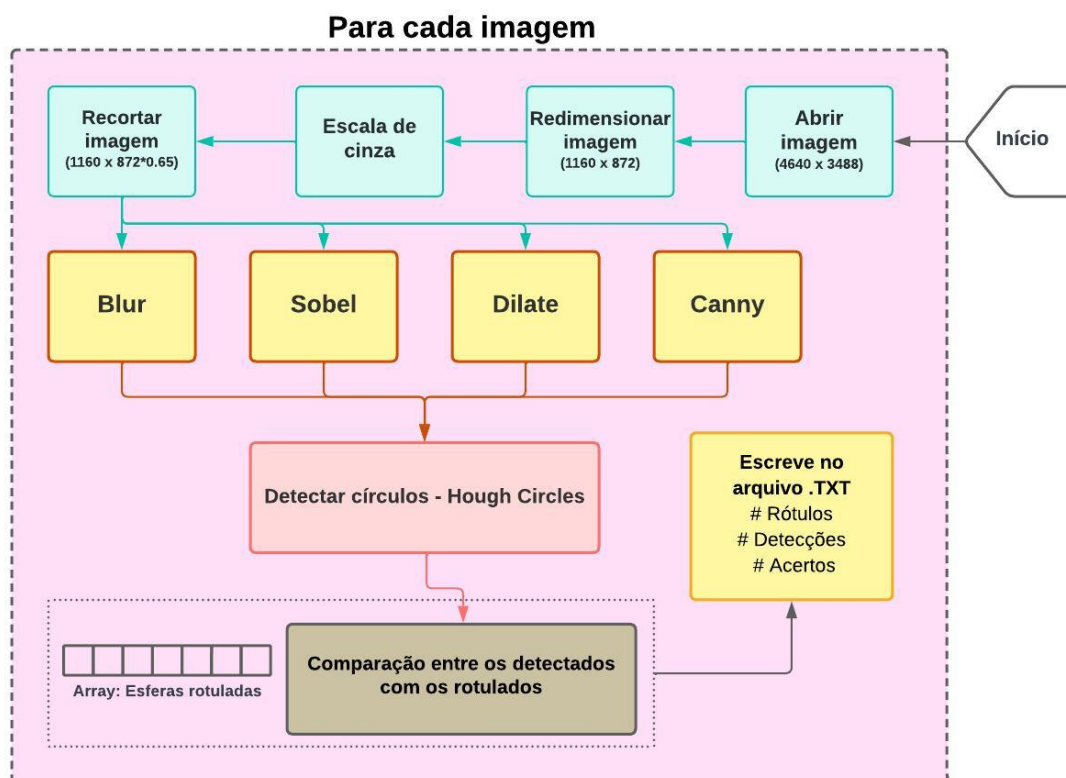


Figura 1. Fluxo do Script desenvolvido.

Ao fim do processamento das imagens, os vetores que armazenaram os círculos identificados e os que corresponderam com as anotações são inscritos em um arquivo de texto, afim de armazenar os resultados para geração dos gráficos com um script próprio.

Os parâmetros adotados para HoughCircles (HC) em cada etapa foram escolhidos baseados na análise dos resultados obtidos em testes anteriores. Na figura 2 a seguir, representamos como o processo foi executado. O script desenvolvido foi executado va-

riando os parâmetros como constam na tabela 1. O processo de geração de gráficos representam os valores obtidos para cada combinação de parâmetros, onde nas etapas 1 e 2 são plotadas as esferas totais detectadas com o HC e as correspondências com as esferas rotuladas.

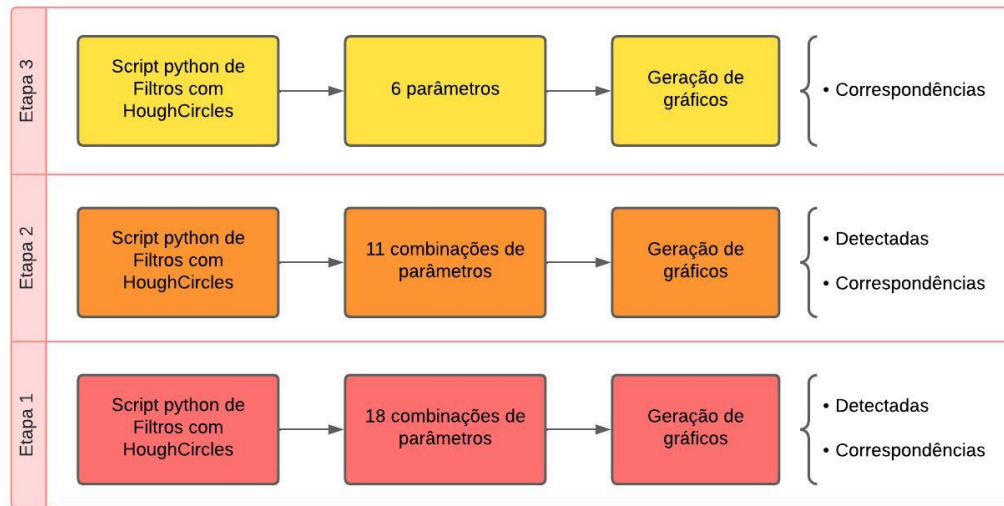


Figura 2. Variação de parâmetros adotados em cada etapa.

5. Resultados

Para avaliar a eficácia dos filtros de pré-processamento e do algoritmo Hough Circles na detecção de esferas. Temos dois tipos de classes rotuladas as "esferas" e "esferas-ocultas", que se baseiam na visibilidade da esferas na imagem. Foram gerados gráficos representando duas principais métricas: esferas detectadas e esferas identificadas.

Como referência para avaliar a precisão dos métodos de detecção, as esferas anotadas contabilizam 564 esferas evidentes e 58 esferas ocultas em 219 imagens, rotuladas manualmente utilizando a plataforma CVAT.

A figura 3 exibe um grid 3x4, exemplificando as diferentes etapas do processamento. Na primeira linha, vemos as imagens originais, que mostram esferas dispostas aleatória em uma sala de fundo branco e teto aberto. Na segunda linha, as imagens estão rotuladas com CVAT, destacando as esferas evidentes (em roxo) e esferas ocultas (em azul-claro), indicando as anotações manuais feitas com a ferramenta.

A terceira linha apresenta as imagens após a aplicação do algoritmo HoughCircles, com círculos vermelhos sobrepostos nas esferas, resultado do processamento com filtros variados. Finalmente, na quarta linha, as imagens mostram as esferas identificadas, com círculos roxos são as circunferências identificadas a após a combinação de filtros, aplicação do HoughCircles e comparação entre centros note que na ultima imagem da (d), uma esfera oclusa não foi identificada.

A linha (c) após HoughCircles ser aplicado, é uns dos pontos principais que o trabalho desenvolvido é aplicado, visto que observamos inúmeros falsos positivos, de circunferências detectadas. Para melhor compreendermos isso, os gráficos de esferas




Figura 3. Imagens originais das esferas no ambiente(a). Imagens rotuladas com CVAT, destacando manualmente as esferas em roxo e azul-claro (b). Imagens após a aplicação do algoritmo HoughCircles com diferentes filtros, mostrando as detecções em círculos vermelhos (c). Imagens com esferas identificadas corretamente, usando filtros, HoughCircles e comparação entre centros, destacadas em círculos roxos (d).

detectadas (figuras 5 e 7) apresentam os números de esferas encontradas após a aplicação dos diferentes filtros de pré-processamento.

A quantidade de esferas identificadas são representadas pelos gráficos das figuras 4 e 6. A escala apresentada mostra o valor percentual da relação entre as esferas identificadas e o número de esferas rotuladas em cada imagem, sendo essa uma representação importante para entender a capacidade do algoritmo em encontrar esferas nas imagens processadas.

5.1. Etapa 1

Analisando o gráfico ilustrado na figura 4, avaliando as esferas evidentes, para o parâmetro dp , o filtro sobel mantém a melhor performance em todas as variações, enquanto o filtro edges apresenta os piores resultados. O valor $dp = 1.05$ destaca-se pela alta taxa de detecção para sobel. Quanto ao parâmetro $minDist$, conforme o valor aumenta, a detecção diminui significativamente para todos os filtros, sendo mais eficaz com $minDist = 40$, especialmente para sobel e blur.

O parâmetro $p1$, a detecção diminui com o aumento do valor, mas sobel continua sendo o mais eficaz. O valor $p1 = 85$ proporciona a melhor detecção. No caso do parâmetro $p2$, há uma leve queda na detecção com o aumento dos valores, com sobel mantendo a performance mais alta. Analisando o $minRad$, a detecção é alta para os valores 15 e 20, mas cai significativamente em $minRad = 25$, especialmente para sobel e blur. O valor $minRad = 20$ mantém um equilíbrio na detecção. Por fim, para o parâmetro $maxRad$, há uma leve queda na detecção com o aumento dos valores, especialmente para blur e edges.

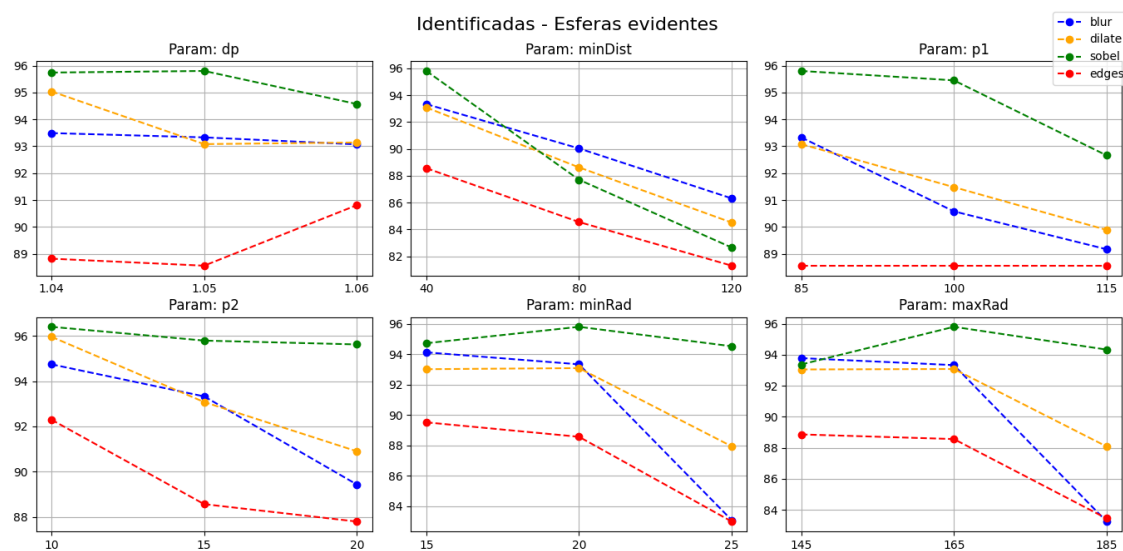


Figura 4. O gráfico apresenta a porcentagem de esferas identificadas para diferentes valores de parâmetros do algoritmo Hough Circles (HC), considerando quatro tipos de filtros de pré-processamento: blur, dilate, sobel e edges. Cada subgráfico representa a variação de um parâmetro específico enquanto os outros permanecem fixos.

Os gráficos de esferas detectadas da figura 5 revelam que o filtro sobel consistentemente apresenta o maior número de detecções para todos os valores do parâmetro dp ,

indicando uma maior incidência de falsos positivos, é importante ressaltar que os valores de referência é de 564 esferas. O filtro edges também mostra altos valores de detecção, enquanto o filtro blur mantém a menor quantidade de detecções, sugerindo menos falsos positivos e uma performance mais desejável. O aumento do valor de $minDist$ resulta em uma queda acentuada nas detecções, com sobel e edges apresentando uma diminuição significativa, mas ainda mantendo altos valores. O filtro blur continua a apresentar os menores valores de detecção. Quando parâmetro $p1$ aumenta, observa-se a tendência de diminuir o número de detecções. Sobel apresenta uma leve redução nas detecções, enquanto edges mantém números elevados, em relação a ele mesmo. O filtro blur destaca-se com o menor número de detecções em todos os valores, indicando uma baixa taxa de falsos positivos. No caso do parâmetro $p2$, há uma tendência geral de aumento no número de detecções com valores mais altos, com sobel e edges mantendo altos valores, enquanto blur permanece relativamente baixo.

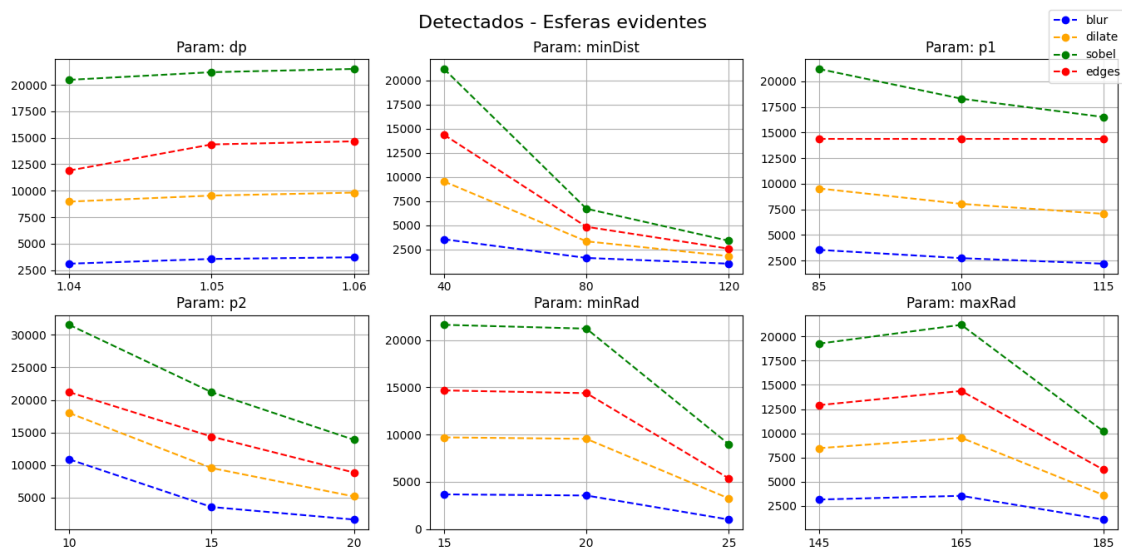


Figura 5. Esferas evidentes identificadas: Para cada filtro, notamos como os parâmetros atuam convergindo ou divergindo para detecção das circunferências.

Quando analisamos o parâmetro $minRad$, os valores de detecção aumentam ligeiramente com $minRad = 25$ para todos os filtros. Sobel continua a detectar mais esferas, seguido por edges, enquanto blur segue apresentando o menor número de detecções, sendo o mais eficiente em evitar falsos positivos. Finalmente, para o parâmetro $maxRad$, o número de detecções diminui à medida que o valor aumenta. Sobel e edges mostram os números mais altos, enquanto blur e dilate mantêm números menores, com blur sendo consistentemente o melhor em evitar falsos positivos.

Os gráficos também mostram que as esferas anotadas como *esferas-occlusas* são mais difíceis de detectar corretamente, o que era esperado devido às suas características de ocultação parcial e sobreposição.

Os gráficos nas figuras 6 e 7 avaliam as esferas rotuladas como oclusas. Nesses gráficos, podemos observar como os parâmetros atuam em conjunto com os filtros. Os parâmetros que utilizam os valores mínimos adotados para cada situação obtêm os melhores resultados na maioria dos casos.

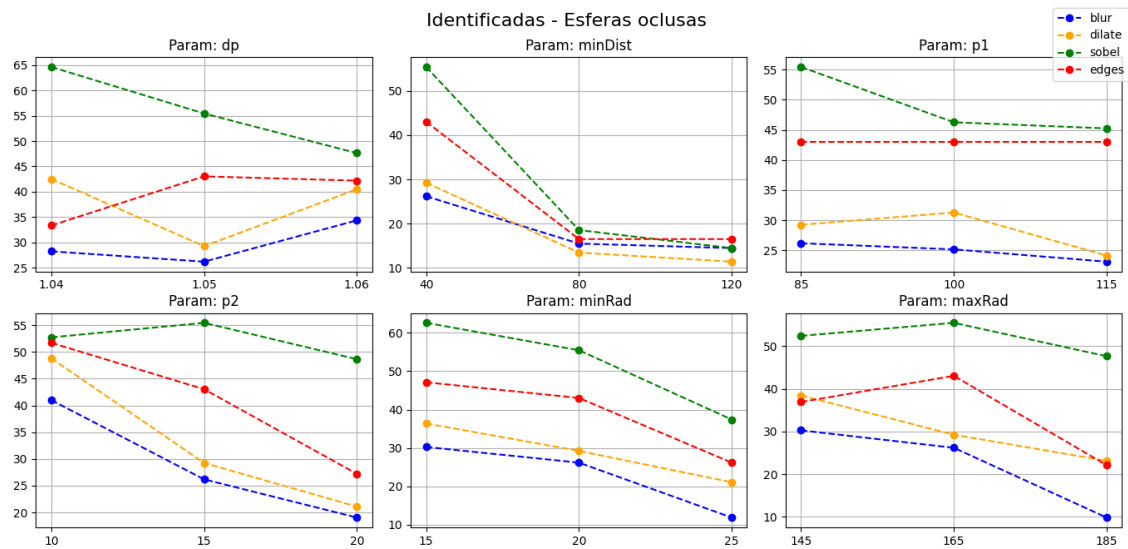


Figura 6. Esferas oclusas identificadas: Sobel se destaca como filtro com melhor percentual de acerto, e blur tem o menor percentual.

O que se deve à natureza das esferas oclusas, apresentam maior dificuldade na detecção. Em relação aos filtros, o Sobel se destaca com os melhores resultados.

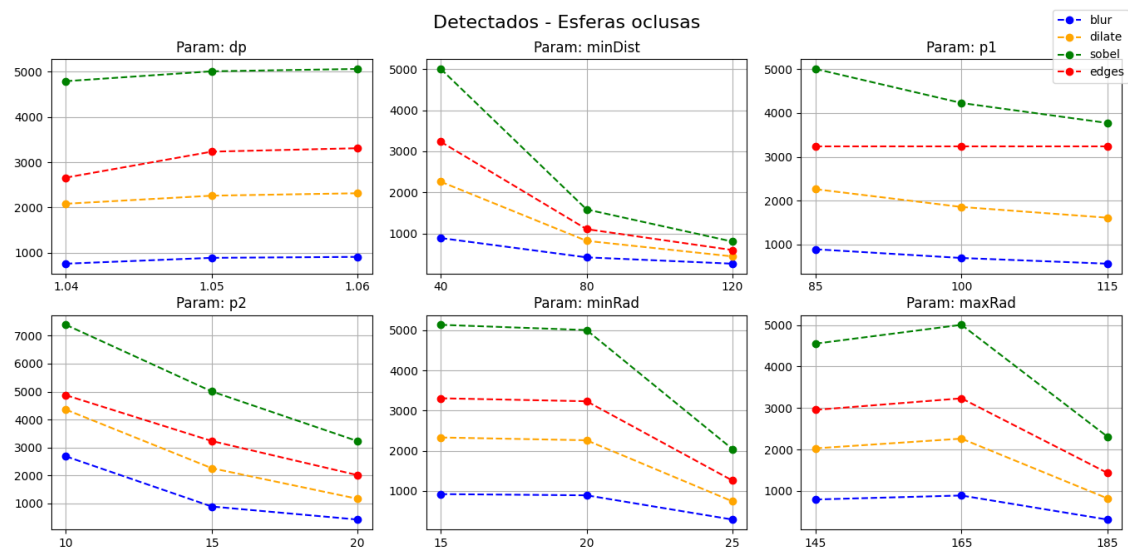


Figura 7. Esferas oclusas detectadas: Exceto para o filtro *dp*, a medida que os parâmetros aumentam, temos uma diminuição das esferas detectadas.

Nos gráficos de esferas detectadas, há uma clara semelhança com as esferas evidentes, com a principal diferença sendo a proporção, dado o menor número de amostras para as esferas oclusas, sendo 58 as esferas oclusas rotuladas.

5.2. Etapa 2

Na segunda etapa, os testes foram realizados com os parâmetros que convergiam para os melhores resultados gerais da etapa 1, independente o filtro utilizado, como demonstrado na tabela 1.

Os resultados obtidos das esferas evidentes na segunda etapa (figura 8) revela que vários conjuntos de parâmetros atingiram uma taxa de detecção acima de 90%. O filtro Sobel, com a configuração de HC: (1.05, 20.0, 75.0, 15.0, 15.0, 165.0), alcançou a taxa de detecção mais alta de 99.7%, seguido por outras configurações que também demonstraram uma excelente performance. Isso sugere que o Sobel é muito eficiente na identificação das esferas quando bem ajustado, e fazendo a comparação da distância entre centros.

O filtro Dilate também apresentou uma alta taxa de detecção, atingindo 99.1% com os parâmetros de HC: (1.05, 20.0, 75.0, 15.0, 15.0, 165.0). O filtro Blur, embora geralmente é melhor em evitar falsos positivos, também mostrou um desempenho robusto, alcançando até 97.6% com a mesma configuração de parâmetros. Por outro lado, os filtros que apresentaram desempenho abaixo de 90% evidenciam a importância crítica do ajuste fino dos parâmetros, uma vez que configurações inadequadas podem resultar em uma significativa queda na eficácia da detecção.

Configurações como HC: (1.04, 120.0, 115.0, 20.0, 25.0, 165.0) resultam em uma significativa queda na eficácia da detecção devido ao aumento dos valores, que reduz a sensibilidade do algoritmo a detalhes menores ou sutis. Embora esses valores de parâmetros sejam escolhidos para reduzir o número de falsos positivos, acabam se tornando inadequados em termos de precisão da identificação.




Figura 8. O gráfico de barras apresenta a porcentagem de esferas identificadas para diferentes valores de parâmetros do algoritmo Hough Circles (HC), considerando quatro tipos de filtros de pré-processamento, com uma vantagem do Sobel.

Ao analisar as esferas oclusas, notamos que a eficácia dos filtros varia significativamente com as diferentes configurações de parâmetros (figura 9). Para o filtro Sobel, a configuração de HC: (1.05, 20.0, 75.0, 15.0, 15.0, 165.0) resultou na maior taxa de detecção, alcançando 89.8%. Os filtros edges e dilate também apresentaram comportamentos semelhantes. Por exemplo, a configuração de HC: (1.05, 20.0, 75.0, 15.0, 15.0, 165.0) para edges resultou em 66.5%, enquanto para dilate, a configuração teve um desempenho de 69.6%. Em contrapartida, o filtro blur apresentou taxas de detecção abaixo de 55.3% na maioria das configurações, sugerindo que não é o mais adequado para esferas oclusas.




Figura 9. Esferas oclusas detectadas, o gráfico de barras nos mostra uma considerável vantagem do Sobel em relação aos outros filtros.

5.3. Etapa 3

Na terceira etapa, realiza-se a análise do gráfico da figura 10, utilizando os melhores resultados obtidos na etapa 2, como consta na tabela 1. Cada barra do gráfico é dividida em duas partes: a parte sólida indica a taxa de detecção de esferas evidentes, enquanto a parte hachurada representa a taxa de detecção de esferas oclusas.

O filtro Blur apresenta uma grande disparidade entre a detecção de esferas evidentes (94.75%) e oclusas (44.22%), indicando que não é adequado para cenários onde as esferas podem estar parcialmente ocultas. Edges também exibe uma boa performance na detecção de esferas evidentes (97.55%), mas sua eficácia reduz-se substancialmente para esferas oclusas (66.50%), sugerindo que não é tão confiável para situações mais complexas com obstruções.

Em contraste, o filtro dilate demonstra alta eficácia para esferas evidentes (99.08%) e um desempenho razoável para esferas oclusas (69.56%), indicando que é uma boa escolha para esferas evidentes e mantém um desempenho aceitável para esferas oclusas. Já o filtro Sobel se destaca como o mais robusto e confiável entre todos os analisados, com uma taxa de detecção de 99.73% para esferas evidentes e 89.90% para esferas oclusas, tornando-se a melhor opção para cenários que exigem alta precisão em ambas as situações.




Figura 10. Esferas oclusas detectadas

5.4. Discussões

O filtro Sobel se destaca pelo seu melhor desempenho na detecção de esferas em comparação com os filtros dilate, blur e edges devido a várias razões. Primeiramente, a capacidade do Sobel de detectar bordas é superior, pois ele realça mudanças abruptas de intensidade ao calcular as derivadas da imagem em direções horizontais e verticais. Isso resulta em uma representação clara das bordas dos objetos, o que é desejado para a identificação das esferas, facilitando significativamente o trabalho do algoritmo Hough Circles. Em contraste, filtros como o blur tendem a suavizar a imagem, o que pode resultar na perda de detalhes cruciais e na diminuição da precisão da detecção de bordas.

Embora o Sobel não seja diretamente um filtro de redução de ruído, ele aplica uma suavização inicial que ajuda a mitigar pequenos ruídos antes de calcular as derivadas. Isso contribui para uma melhor distinção entre bordas reais e ruído. O filtro Canny, apesar de ser um bom detector de bordas, envolve várias etapas complexas, como suavização e supressão de não-máximos, o que pode levar à perda de detalhes finos e aumentar a complexidade do processo.

O Sobel é também computacionalmente menos intensivo e mais direto na sua aplicação em comparação com o Canny, que envolve múltiplas etapas como suavização, cálculo de gradientes, supressão de não-máximos e rastreamento de bordas por histerese. A dilatação, por outro lado, é uma operação morfológica que tende a expandir áreas de borda, podendo preencher lacunas, mas também levar à fusão de bordas próximas, dificultando a separação de esferas próximas.

Filtros como dilate são úteis para conectar componentes e preencher lacunas, mas podem resultar em perda de precisão nas bordas das esferas, porém obteve bons resultados nessa aplicação. O filtro blur é eficaz para redução de ruído, mas pode suavizar bordas críticas, dificultando a detecção precisa.

Por curiosidade, devido aos bons desempenhos individuais do Sobel e do dilate, decidiu-se testar a combinação desses dois filtros para avaliar seu comportamento con-

junto. A união de dilate + Sobel mostrou-se eficaz na captura de bordas nítidas e preenchimento de lacunas, resultando em uma melhoria geral na detecção, porém pouco significativa. Contudo, para esferas oclusas, embora a combinação tenha superado o desempenho do filtro dilate isolado, não alcançou os resultados do filtro Sobel utilizado sozinho.

6. Conclusões

A partir da análise dos gráficos, constatamos que a quantidade de esferas detectadas apresenta variações significativas em função dos parâmetros do método Hough Circles e dos filtros de pré-processamento empregados. Os resultados sugerem que, para otimizar a detecção de esferas em condições similares às observadas na OBR, é fundamental realizar um ajuste minucioso dos parâmetros do Hough Circles, além de selecionar filtros de pré-processamento apropriados.

As esferas denominadas *esferas-occlusas* representam um desafio adicional, indicando a necessidade de técnicas de detecção mais avançadas para lidar com essas situações. Com base nos dados obtidos, pode-se inferir que o filtro Sobel é o mais eficaz tanto para esferas evidentes quanto para esferas oclusas, sendo a escolha recomendada para ambos os contextos. O filtro dilate também mostra bons resultados para esferas evidentes, mas sua eficácia diminui no caso das esferas oclusas. Embora o filtro blur apresente um bom desempenho para esferas evidentes, ele não é adequado para a detecção de esferas oclusas. O filtro edges, apesar de apresentar um desempenho relativamente bom, é inferior ao Sobel e ao dilate para a detecção de ambos os tipos de esferas.

No entanto, os gráficos de esferas detectadas revelam que o filtro Sobel também gera um número significativo de falsos positivos em comparação com o filtro Blur, que, embora identifique menos esferas, resulta em menos falsos positivos. Para futuros trabalhos, um objetivo importante será alcançar a mesma eficácia de identificação de esferas do filtro Sobel, mas utilizando o filtro Blur. Isso representaria um avanço significativo, pois possibilitaria a obtenção dos melhores valores de esferas identificadas, alinhados aos objetos rotulados, ao mesmo tempo em que se minimizaria a ocorrência de falsos positivos.

Referências

- Aggarwal, A. M. (2012). Comparative analysis of image segmentation using hough transform. *International Journal of Applied Engineering Research*, 7(11):2012.
- Eisenkraemer, M. F. (2016). Sistema de detecção de veículos e avaliação de eixos por meio de máquina de vetor de suporte.
- Rizal, M. F., Sarno, R., and Sabilla, S. I. (2020). Canny edge and hough circle transformation for detecting computer answer sheets. In *2020 International Seminar on Application for Technology of Information and Communication (iSemantic)*, pages 346–352.